

Инструкция по воспроизведению результата

1. Клонирование репозитория

Сначала необходимо скачать репозиторий с решением:

```
git clone <ссылка-на-репозиторий>  
cd <название-репозитория>
```

2. Подготовка данных

В корень проекта или в папку с ноутбуком необходимо поместить файлы соревнования:

```
train.csv  
test.csv  
sample_submission.csv
```

Структура проекта может выглядеть так:

```
project/  
├─ README.md  
├─ requirements.txt  
├─ hackathon_solution.ipynb  
├─ train.csv  
├─ test.csv  
└─ sample_submission.csv
```

Если файлы данных лежат в другой папке, путь к ним нужно указать в переменной `DATA_DIR` внутри ноутбука.

Пример:

```
DATA_DIR = r"C:\path\to\data"
```

Если файлы лежат рядом с ноутбуком, можно оставить:

```
DATA_DIR = None
```

3. Создание виртуального окружения

Рекомендуется запускать решение в отдельном Python-окружении.

Для Windows:

```
python -m venv .venv  
.venv\Scripts\activate
```

Для Linux / macOS:

```
python3 -m venv .venv  
source .venv/bin/activate
```

4. Установка зависимостей

После активации окружения нужно установить зависимости:

```
pip install -r requirements.txt
```

Файл `requirements.txt` должен содержать основные библиотеки:

```
pandas  
numpy  
scikit-learn  
matplotlib  
catboost  
lightgbm  
xgboost  
jupyter  
notebook
```

Если `catboost`, `lightgbm` или `xgboost` не установлены, ноутбук может выполняться, но часть моделей будет пропущена. В этом случае итоговый результат может отличаться от финального.

5. Запуск ноутбука

Открыть Jupyter Notebook:

```
jupyter notebook
```

Затем открыть файл с решением:

```
hackathon_solution.ipynb
```

В меню ноутбука выполнить:

Kernel → Restart & Run All

Это перезапустит ядро и выполнит все ячейки сверху вниз.

6. Что происходит при запуске

Ноутбук выполняет полный пайплайн:

1. загружает `train.csv`, `test.csv`, `sample_submission.csv`;
2. проводит первичный анализ данных;
3. подготавливает признаки;
4. обучает отдельные модели для `IC50`, `CC50` и `SI`;
5. строит OOF-предсказания по 5-fold cross-validation;
6. объединяет модели через weighted blend;
7. применяет Ridge stacking;
8. выполняет финальную постобработку;
9. сохраняет итоговый файл `submission.csv`.

7. Итоговый файл

После успешного выполнения всех ячеек в рабочей папке появится файл:

`submission.csv`

Именно этот файл нужно отправлять в систему соревнования.

Перед финальным сохранением ноутбук удаляет промежуточные файлы вида:

`submission_*.csv`
`candidate_*.csv`

Это сделано для того, чтобы в папке оставался только один итоговый файл и не было риска случайно отправить экспериментальный вариант.

8. Проверка результата

После выполнения финальной ячейки в ноутбуке выводится информация о сохранённом файле и статистика предсказаний.

Необходимо убедиться, что:

- файл `submission.csv` создан;
- количество строк совпадает с `sample_submission.csv`;
- в файле нет `NaN`;
- в файле нет бесконечных значений `inf`.

9. Воспроизводимость

Для воспроизводимости в решении используются фиксированные значения `random_state`.

Решение не использует:

- внешние данные;
- целевые значения тестовой выборки;
- ручную правку `submission.csv`;
- признаки, построенные на основе target из `test`.

Все этапы построения результата выполняются внутри ноутбука.